Bike Sharing Dataset

LINK SURSA: https://www.kaggle.com/datasets/yasserh/bike-sharing-dataset

1. Am incarcat setul de date cu functia **df=pd.read_csv** si am afisat primele 5 randuri ca sa intelegem mai bine datele cu care lucram cu **df.head().**

Am constatat ca setul de date contine informatii zilnice despre inchirierea bicicletelor, fiecare inregistrare corespunzand unei zile calendaristice.

- **instant** – identificator unic
- **dteday** – data calendaristica
- **season** – anotimpul
- **yr** – anul (0 = 2018, 1 = 2019)
- **mnth** – luna
- **holiday** – indica daca ziua este sarbatoare
- **weekday** – ziua saptamanii
- **workingday** – indica zi lucrătoare
- **weathersit** – starea vremii
- **temp** – temperatura normala
- **atemp** – temperatura resimtita
- **hum** – umiditatea
- **windspeed** – viteza vantului
- **casual** – utilizatori ocazionali
- **registered** – utilizatori inregistrati
- **cnt** – numarul total de inchirieri

```
Primele 5 randuri din setul de date sunt:
   instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
0        1  01-01-2018       1   0     1        0        6           0
1        2  02-01-2018       1   0     1        0        0           0
2        3  03-01-2018       1   0     1        0        1           1
3        4  04-01-2018       1   0     1        0        2           1
4        5  05-01-2018       1   0     1        0        3           1

   weathersit       temp     atemp      hum  windspeed  casual  registered
0           2  14.110847  18.18125  80.5833  10.749882     331         654
1           2  14.902598  17.68695  69.6087  16.652113     131         670
2           1   8.050924   9.47025  43.7273  16.636703     120        1229
3           1   8.200000  10.60610  59.0435  10.739832     108        1454
4           1   9.305237  11.46350  43.6957  12.522300      82        1518

    cnt
0   985
1   801
2  1349
3  1562
4  1600
```

2. Am aflat numarul de inregistrari si de coloane cu functia **df.shape** si am aflat ca setul de date contine **730 de inregistrari(linii)** si **16 coloane**.

```
Numarul de inregistrari si de coloane este: (730, 16)
```

3. Am verificat daca exista valori null pe fiecare coloana cu functia **df.isnull().sum()**,rezultatul obtinut arata ca **fiecare coloana are 0 valori null** si astfel nu a fost nevoie sa folosim functii precum **df.dropna**.Am vrut sa fim 100% siguri ca nu avem valori null si am folosit si functia **df.isnull().values.any()** si am primit rezultatul dorit.

```
Valorile lipsa de pe fiecare coloana sunt:
instant       0
dteday        0
...
registered    0
cnt           0
dtype: int64
Exista valori lipsa in setul de date?:
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

np.False_
```

4. Am extras initial coloanele numerice relevante pentru a calcula **media**,**mediana**,**deviatia standard**,**cvartiile**,iar aceste coloane sunt:**temp,atemp,hum,windspeed,casual,registered si cnt.**

Media am calculat-o cu functia **mean().**Eareprezinta valoarea medie a tuturor datelor si se obtine adunand toate valorile si impartind la numarul acestora.

```
print(df[cols_numerice].mean())
✓ 0.0s

temp            20.319259
atemp           23.726322
hum             62.765175
windspeed       12.763620
casual         849.249315
registered    3658.757534
cnt           4508.006849
dtype: float64
```

Mediana am calulat-o cu functia **median(). Mediana (50%):** Este valoarea de la mijlocul sirului de date ordonate crescator. Jumatate din zile au valori mai mici decat mediana, jumatate mai mari.

```
print(df[cols_numerice].median())
```

4] ✓ 0.0s

```
temp            20.465826
atemp           24.368225
hum             62.625000
windspeed       12.125325
casual         717.000000
registered    3664.500000
cnt           4548.500000
dtype: float64
```

Deviatia standard am calculat-o cu functia **std(). Deviatia standard** arata cat de imprastiate sunt datele noastra fata de medie.O deviatie mica indica faptul ca datele sunt grupate aproape de medie,iar una mare indica faptul ca exista variatii mari de la o zi la alta.

```
print(df[cols_numerice].std())
```

2] ✓ 0.0s

```
temp            7.506729
atemp           8.150308
hum            14.237589
windspeed       5.195841
casual        686.479875
registered   1559.758728
cnt          1936.011647
dtype: float64
```

Cvartiile au fost obtinute cu functia **quantile(0.25,0.5,0.75). Impart clientii in 4 grupe egale(4 felii de pizza).Cvartiile** sunt masuri statistice de pozitie care impart un set de date ordonat în patru parti egale, fiecare continand aproximativ 25% din observatii. Exista trei cvartile: primul cvartil (Q1 – 25%), al doilea cvartil (Q2 – mediana – 50%) si al treilea cvartil (Q3 – 75%). Sunt trei cvartile deoarece sunt necesare doar trei puncte de separare pentru a imparti datele în patru intervale. Cvartiile sunt utilizate pentru a analiza distributia datelor, pentru identificarea valorilor extreme si pentru compararea medianei cu media.

```
print(df[cols_numerice].quantile([0.25,0.5,0.75]))
```

✓ 0.0s

	temp	atemp	hum	windspeed	casual	registered	cnt
0.25	13.811885	16.889713	52.000000	9.041650	316.25	2502.25	3169.75
0.50	20.465826	24.368225	62.625000	12.125325	717.00	3664.50	4548.50
0.75	26.880615	30.445775	72.989575	15.625589	1096.50	4783.25	5966.00

Am realizat un tabel mai ordonat cu functia **display** pentru a putea vizualiza mai bine media,mediana,deviatia standard si cvartiile toate la un loc.

```
Tabel cu media, mediana, deviata standard si cvartiile pentru valorile numerice:
```

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

	temp	atemp	hum	windspeed	casual	registered	cnt
mean	20.319259	23.726322	62.765175	12.763620	849.249315	3658.757534	4508.006849
50%	20.465826	24.368225	62.625000	12.125325	717.000000	3664.500000	4548.500000
std	7.506729	8.150308	14.237589	5.195841	686.479875	1559.758728	1936.011647
25%	13.811885	16.889713	52.000000	9.041650	316.250000	2502.250000	3169.750000
75%	26.880615	30.445775	72.989575	15.625589	1096.500000	4783.250000	5966.000000

Analiza Medie-Mediana

Media ≈ Mediana (**temp,hum,registered,cnt**): distributie **aproximativ simetrica**.

Media > Mediana (**casual, windspeed**): distributie **asimetrica pozitiv (spre dreapta)**, determinata de existenta unor valori foarte mari in anumite zile.

Media < Mediana (**atemp**) Indică o distribuție **asimetrică negativ (spre stanga)**, determinata de existenta unor valori mai scazute.

Analiza Deviatiile Standard

Deviatie standard mica raportata la medie (temp,atemp,hum,windspeed)=variatie redusa/moderata –valorile au fluctuatii mici de la o zi la alta,sunt concentrate in jurul mediei

Deviatie standard mare raportata la medie (casual)=variatie ridicata- cererea utilizatorilor ocazionali variaza puternic intre zile, fiind influentata de factori sezonieri si meteorologici

Deviatie standard mare,dar mai mica decat media (registered,cnt)=variatie ridicta,dar structurata- valorile sunt relativ bine concentrate în jurul mediei, indicand un comportament mai stabil comparativ cu utilizatorii ocazionali

Analiza Cvartili

Cvartili (Q1-Mediana-Q3)

Distributie aproximativ simetrica (temp,hum,registered,cnt) -Q1 și Q3 sunt relativ echidistante fata de mediana

Distributie asimetrica pozitiv (spre dreapta) (casual,windspeed)-mediana mai aproape de Q1

Distributie asimetrica negativ (spre stanga) (atemp)-mediana mai aproape de Q3

5. **Variabilele categoriale si Explicatii**

- **season**
  Reprezinta anotimpul in care s-au inregistrat datele. Sunt 4 valori posibile:
  1 = iarna, 2 = primavara, 3 = vara, 4 = toamna.
  Este o variabila categoriala deoarece anotimpurile sunt categorii distincte fara un raport numeric intre ele.
- **year**
  Reprezinta anul in care s-au colectat datele (2018=0, 2019=1).
  Este o variabila categoriala deoarece reprezinta ani diferiti (perioade distincte), iar codarea 0/1 este doar conventionala, fara semnificatie numerica.
- **month**
  Indica luna calendaristica (1-12).
  Este o variabila categoriala deoarece fiecare luna este o categorie distincta si modelele pot interpreta diferit fiecare luna.
- **holiday**
  Indica daca ziua este o sarbatoare legala sau nu (0 = nu, 1 = da).
  Este categoriala pentru ca exprima doua categorii (sarbatoare sau nu).
- **workingday**
  Indica daca ziua este o zi lucratoare (0 = nu, 1 = da).
  Este o variabila categoriala binara.
- **weekday**
  Reprezinta ziua saptamanii, cu valori de la 0 la 6 (0 = duminica, 1 = luni, etc.).
  Este o variabila categoriala deoarece fiecare zi este o categorie separata.
- **weathersit**
  Descrie conditiile meteo in ziua respectiva, cu valori de la 1 la 3, fiecare corespunzand unei conditii meteo diferite (ex: 1:senin, 2:nori/ceata, 3:ploaie/zapada).
  Este categoriala pentru ca fiecare valoare reprezinta o clasa distincta.

Pentru a afla variabilele categoriale prima data am verifcat cate valori unice are fiecare coloana cu functia **df.nunique()**,iar apoi am filtrate cele care au mai putin de 15 valori si am aflat variabilele categoriale si le-am afisat.

```
Număr de valori unice per coloană:
instant        730
dteday         730
season           4
yr               2
mnth            12
holiday          2
weekday          7
workingday       2
weathersit       3
temp           498
atemp          689
hum            594
windspeed      649
casual         605
registered     678
cnt            695
dtype: int64

Variabilele categoriale identificate sunt:
['season', 'yr', 'mnth', 'holiday', 'weekday', 'workingday', 'weathersit']
```

6. **Analiza diferentelor intre medii** am calculat-o cu ajutorul functiei **df.groupby()** si am realizat diferente intre medii in functie de cele mai relevante aspecte si anume **sezon,conditii meteo** si de **tipul zilei.**

Calcularea diferentelor intre medii ne ajuta sa identificam variabilele cu cel mai mare impact asupra fenomenului studiat. In acest caz, se observa ca factorii de mediu (**sezonul** si **starea vremii**) produc diferente mult mai mari in comportamentul utilizatorilor decat **tipul zilei (lucratoare sau nu).**

- **Diferente in functie de sezon**:

Se observa o diferenta majora intre Sezonul 3 (Vara), care are cea mai mare medie (aprox. 5644 inchirieri/zi) si Sezonul 1 (Iarna), cu cea mai mica medie (aprox. 2608 inchirieri/zi).

Concluzie: Vremea mai calda din timpul verii si primaverii favorizeaza semnificativ inchirierile fata de inceputul anului.

- **Diferente in functie de conditiile meteo:**

Exista o scadere drastica a mediei atunci cand vremea se inrautateste. In zilele cu cer senin (Vremea 1), media este de aproximativ 4876, in timp ce in zilele cu ploaie sau zapada (Vremea 3), media scade la doar 1803.

Concluzie: Starea vremii este cel mai critic factor care determina scaderea cererii.

- **Diferente in functie de tipul zilei (zi lucratoare vs. weekend):**

Media in zilele lucratoare (aprox. 4590) este usor mai mare decat in weekend-uri sau sarbatori (aprox. 4330).

Concluzie: Desi diferenta nu este la fel de mare ca in cazul conditiilor meteo, datele sugereaza ca bicicletele sunt folosite intr-o masura mai mare pentru naveta catre locul de munca decat pentru recreere in weekend.

```
Media pe Sezoane (1:Primăvară, 2:Vară, 3:Toamnă, 4:Iarnă):
season
1    2608.411111
2    4992.331522
3    5644.303191
4    4728.162921
Name: cnt, dtype: float64
Media pe Vreme (1:Limpede, 2:Nori/Ceață, 3:Ploaie/Zăpadă):
weathersit
1    4876.786177
2    4044.813008
3    1803.285714
Name: cnt, dtype: float64
Media Zi Lucrătoare (1) vs Weekend/Sărbătoare (0):
workingday
0    4330.168831
1    4590.332665
Name: cnt, dtype: float64
```

Am realizat un **boxplot** cu 3 subgrafice pentru a vizualiza mai usor diferentele intre medii.

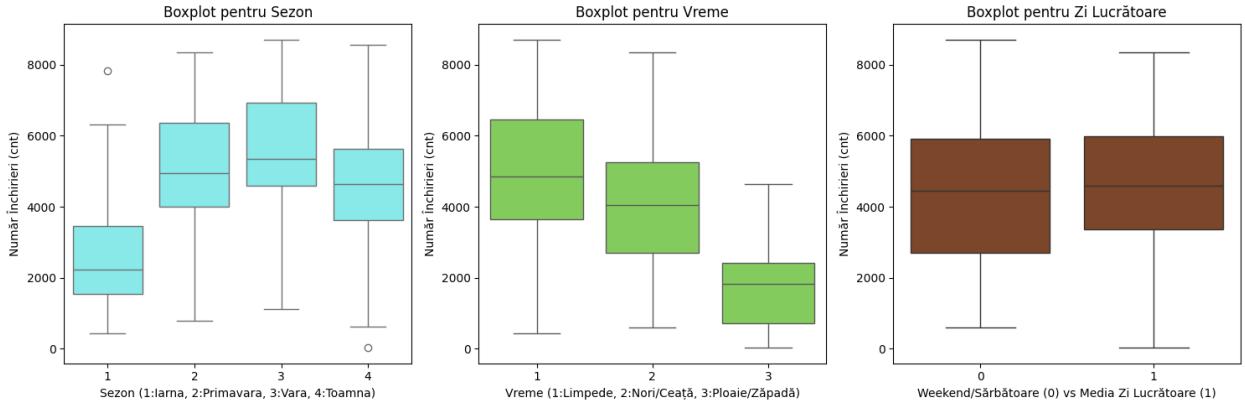

7. **Cele mai importante variabile independente si justificarea alegerii**

In urma analizei statistice a coeficientilor de corelatie și a distributiei datelor, am identificat urmatoarele 3 variabile ca fiind cele mai importante in influentarea numarului de inchirieri:

1. **Temperatura (temp / atemp):** Are cea mai mare corelatie pozitiva (**0.63**).
   - *Justificare:* Aceasta indica faptul ca cererea pentru biciclete este dictata in primul rand de confortul termic. Pe masura ce temperatura creste, numarul de utilizatori creste proportional.
2. **Anul (yr):** Prezinta o corelatie ridicata de **0.57**.
   - *Justificare:* Datele arata o evolutie clara a popularitatii serviciului. Media zilnica a crescut de la aproximativ 3405 inchirieri în 2018 la 5610 în 2019, sugerand o extindere a bazei de clienti.
3. **Starea vremii (weathersit):** Are o corelatie negativa semnificativa (**-0.30**).
   - *Justificare:* Aceasta variabila actioneaza ca un factor perturbator. Corelatia negativa confirma faptul că pe măsura ce vremea se inrautateste (trecerea de la cer senin la ploaie/zăpada), numarul de inchirieri scade drastic.

Nota despre variabilele excluse: Desi variabilele **registered** și **casual** au corelatii extrem de mari cu cnt, acestea **nu au fost incluse** in topul variabilelor independente. Acestea reprezinta de fapt suma care formeaza variabila cnt, fiind variabile "rezultat", nu factori de influenta externi (precum vremea sau timpul).

```
Corelația variabilelor independente cu numărul de închirieri (cnt):
cnt           1.000000
atemp         0.630685
temp          0.627044
yr            0.569728
season        0.404584
mnth          0.278191
weekday       0.067534
workingday    0.062542
holiday      -0.068764
hum          -0.098543
windspeed    -0.235132
weathersit   -0.295929
Name: cnt, dtype: float64

Media închirierilor pe ani (0=2018, 1=2019):
yr
0    3405.761644
1    5610.252055
Name: cnt, dtype: float64
```

8. **Analiza corelațiilor dintre variabile**

Am calculat corelația variabilelor numerice cu funcția **df.corr()** pentru a înțelege cum se leagă acestea între ele și cu numărul de închirieri **(cnt)**.

- Variabilele cu corelație pozitivă mare cu cnt: **temp** (0.63), **atemp** (0.63), **yr** (0.57).
- Variabilele cu corelație negativă: **hum** (-0.099), **weathersit** (-0.30), **windspeed** (-0.24).

Corelația ne ajută să identificăm care factori sunt cei mai importanți în influențarea numărului de închirieri. Totodată, corelația foarte mare între temp și atemp sugerează **coliniaritate** între aceste variabile.

Am vizualizat matricea de corelație printr-un heatmap, pentru a observa rapid relațiile dintre toate variabilele numerice. Această vizualizare ajută la identificarea rapidă a corelațiilor puternice și a variabilelor care pot fi eliminate din modelul de regresie din cauza redundanței.

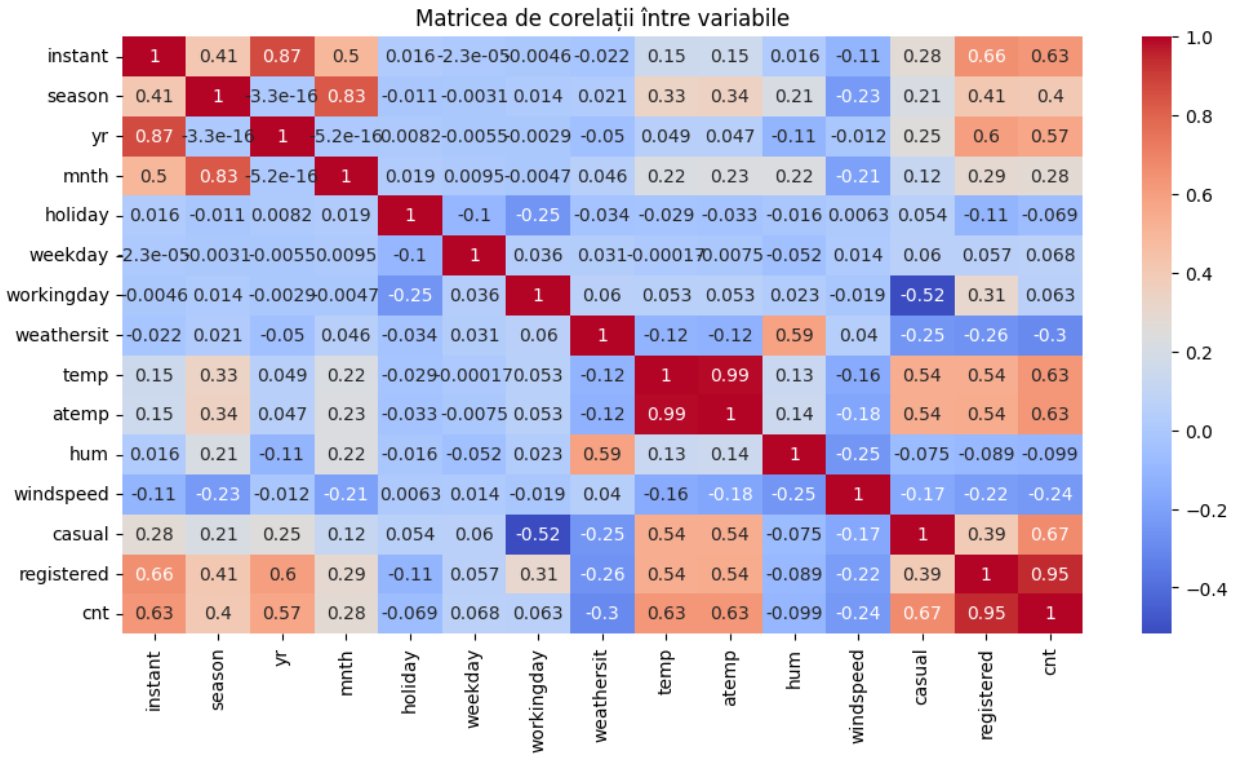

9. Verificare multicoliniaritate VIF

Am calculat **VIF** pentru variabilele independente (**temp, atemp, hum, windspeed**) pentru a detecta coliniaritatea.

- **VIF > 10** indică coliniaritate **puternică**.
- temp și atemp au VIF mare (temp VIF = 488, atemp VIF = 542), ceea ce confirmă corelația lor ridicată.
- Pentru a elimina coliniaritatea, am eliminat variabila **atemp**.

După eliminare, VIF pentru temp, hum și windspeed a scăzut sub 10, ceea ce indică faptul că variabilele rămase nu mai au probleme majore de coliniaritate și pot fi folosite în modelul de regresie liniară.

```
VIF înainte de eliminare:
   Variabila         VIF
0       temp  488.306256
1      atemp  542.888840
2        hum   11.071034
3  windspeed    4.678072

VIF după eliminarea variabilei 'atemp':
   Variabila       VIF
0       temp  7.132959
1        hum  9.052993
2  windspeed  4.677354
```

10. **Pregătirea datelor pentru regresie**

Am eliminat coloanele **instant, dteday, casual, registered** deoarece acestea fie sunt identificatori, fie sunt componente ale variabilei **cnt**.

Am creat variabile dummy pentru variabilele categoriale **season**, **weathersit** și **mnth** folosind pd.get_dummies().

Variabila dependentă este **cnt**, iar variabilele independente sunt toate celelalte coloane numerice și dummy rămase.

```
Setul de date după crearea variabilelor dummy:
   yr  holiday  weekday  workingday       temp      hum  windspeed   cnt  \
0   0        0        6           0  14.110847  80.5833  10.749882   985
1   0        0        0           0  14.902598  69.6087  16.652113   801
2   0        0        1           1   8.050924  43.7273  16.636703  1349
3   0        0        2           1   8.200000  59.0435  10.739832  1562
4   0        0        3           1   9.305237  43.6957  12.522300  1600

   season_2  season_3  ...  mnth_3  mnth_4  mnth_5  mnth_6  mnth_7  mnth_8  \
0     False     False  ...   False   False   False   False   False   False
1     False     False  ...   False   False   False   False   False   False
2     False     False  ...   False   False   False   False   False   False
3     False     False  ...   False   False   False   False   False   False
4     False     False  ...   False   False   False   False   False   False

   mnth_9  mnth_10  mnth_11  mnth_12
0   False    False    False    False
1   False    False    False    False
2   False    False    False    False
3   False    False    False    False
4   False    False    False    False

[5 rows x 24 columns]
```

11. **Regresia liniară**

Am efectuat regresia liniară cu ajutorul **statsmodels.OLS**.

Regresia liniară ne permite să estimăm relația dintre variabilele independente (ex. **temp, hum, windspeed, dummy pentru sezon, vreme** etc.) și variabila dependentă **cnt** (numărul de închirieri).

- Coeficienții pozitivi indică faptul că pe măsură ce variabila crește, cnt crește.
- Coeficienții negativi indică faptul că pe măsură ce variabila crește, cnt scade.
- Interceptul (constanta) reprezintă valoarea estimată a cnt atunci când toate variabilele independente sunt zero.
- R-squared arată cât din variația numărului de închirieri este explicată de model (46%).
- Valorile $p < 0.05$ indică coeficienți semnificativi statistic.

Interpretarea practică: Modelul confirmă că **temperatura și anul** sunt cei mai importanți factori pozitivi, iar **starea vremii și umiditatea** au un efect negativ asupra numărului de închirieri.

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                    cnt   R-squared:                       0.460
Model:                            OLS   Adj. R-squared:                  0.458
Method:                 Least Squares   F-statistic:                     206.1
Date:                Fri, 16 Jan 2026   Prob (F-statistic):           1.06e-96
Time:                        13:45:03   Log-Likelihood:                -6335.3
No. Observations:                 730   AIC:                         1.268e+04
Df Residuals:                     726   BIC:                         1.270e+04
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       4080.3486    337.971     12.073      0.000    3416.832    4743.865
temp         161.3840      7.155     22.556      0.000     147.338     175.430
hum          -30.8447      3.845     -8.021      0.000     -38.394     -23.295
windspeed    -71.7332     10.583     -6.778      0.000     -92.510     -50.956
==============================================================================
Omnibus:                       11.087   Durbin-Watson:                   0.402
Prob(Omnibus):                  0.004   Jarque-Bera (JB):                8.231
Skew:                           0.151   Prob(JB):                       0.0163
Kurtosis:                       2.576   Cond. No.                         439.
==============================================================================
```

12. **Verificarea distribuției variabilei dependente (cnt)**

Am creat un histogram pentru **cnt** cu **sns.histplot()** pentru a vedea distribuția numărului de închirieri zilnice.

Distribuția nu este perfect normală și există câteva valori extreme (zile cu închirieri foarte mari sau foarte mici). Aceasta arată că numărul de închirieri poate varia mult de la o zi la alta.

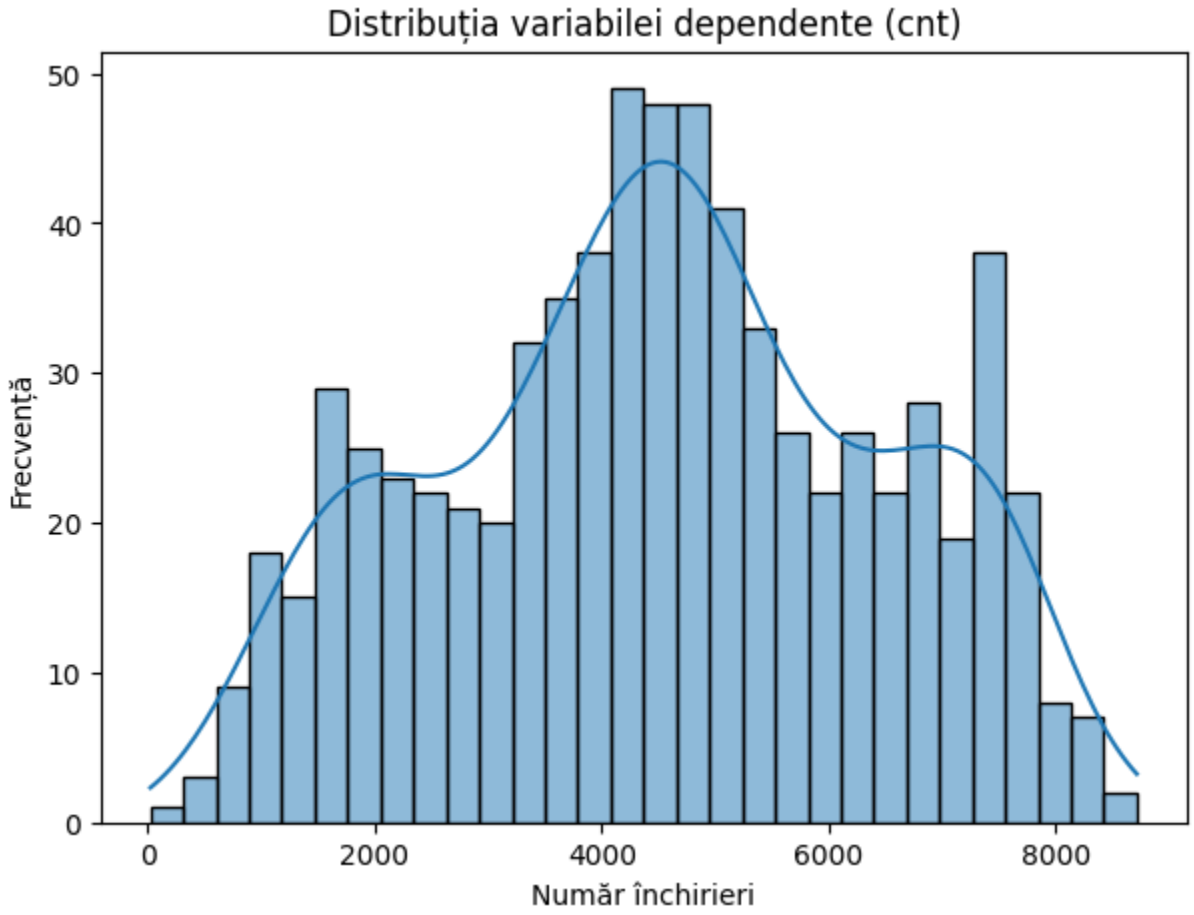

13. **Scatterplot pentru variabilele importante**

Am creat grafice scatter pentru relația dintre variabilele **temp**, **hum** și **windspeed** cu **cnt**.

Interpretare:

- **Temp** vs **cnt**: relație clar pozitivă – pe măsură ce temperatura crește, cresc și închirierile.
- **Hum** vs **cnt**: relație ușor negativă – umiditatea ridicată reduce ușor închirierile.
- **Windspeed** vs **cnt**: relație slab negativă – viteza vântului mai mare tinde să reducă numărul de închirieri.

Aceste grafice ajută la vizualizarea relațiilor individuale și confirmă semnul coeficienților din regresie.

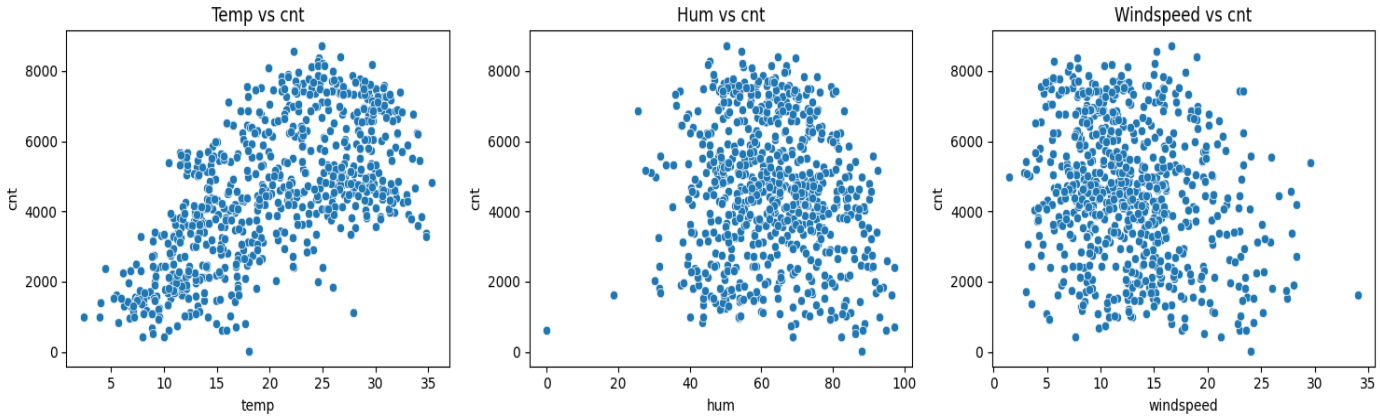

14. **Verificarea reziduurilor modelului**

Am calculat reziduurile (diferența dintre valorile reale **cnt** și valorile estimate de model) și le-am vizualizat prin histogramă.

Interpretare:

- Reziduurile trebuie să fie aproximativ normal distribuite și să aibă variabilitate constantă.
- Histogramă aproape simetrică și fără valori extreme majore indică faptul că modelul se potrivește rezonabil și nu există erori sistematice.

Dacă reziduurile ar fi puternic asimetrice sau cu valori extreme, ar indica probleme în model sau necesitatea transformării variabilei dependente.

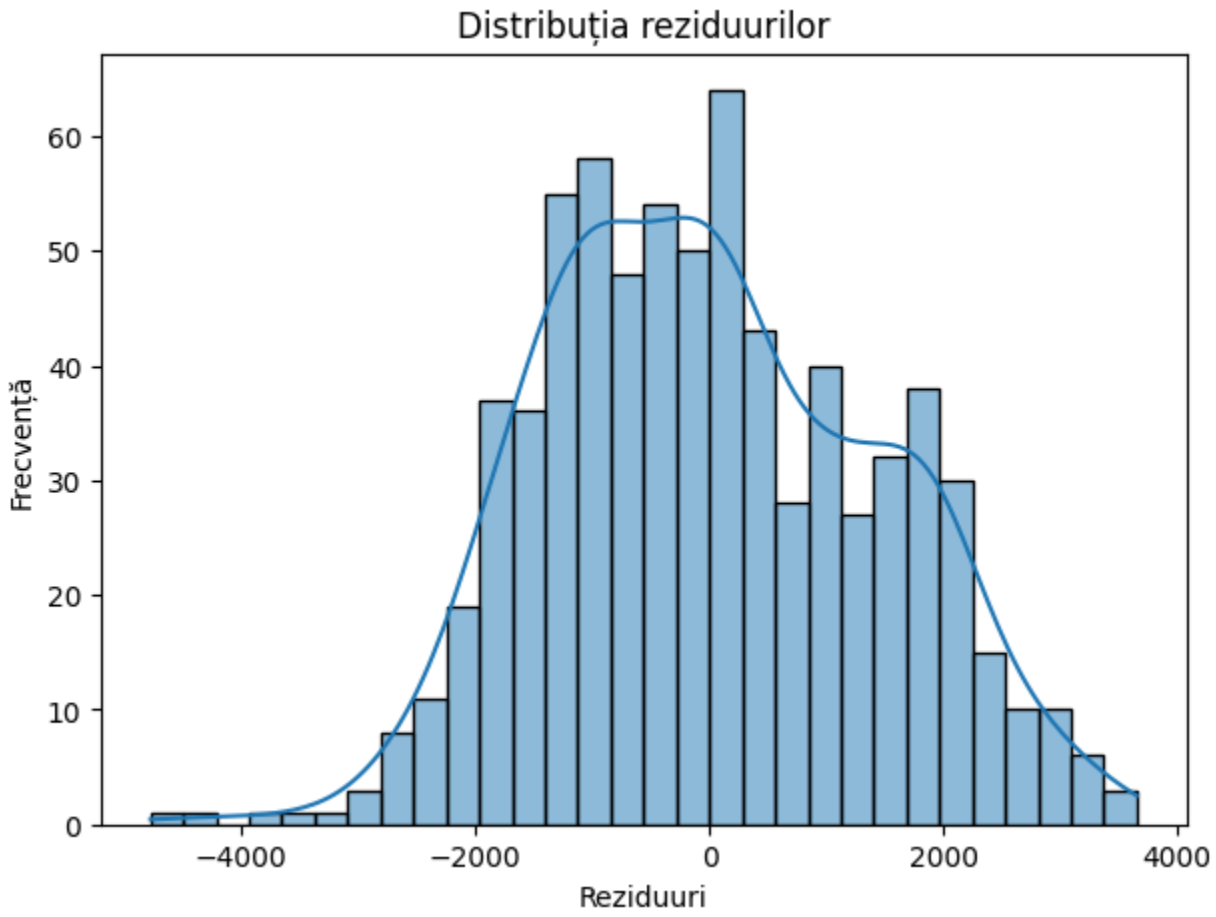

Intrebari specifice setului de date

Întrebarea 1: Care este luna cu cel mai mare număr mediu de închirieri?

- **Răspuns:** Luna **iunie (luna 6)** înregistrează cele mai multe închirieri medii, cu o valoare de **5772** unități.
- **Justificare:** Luna iunie reprezintă vârful sezonului de vară, având condițiile optime de lumină și temperatură pentru utilizatorii de biciclete.

Întrebarea 2: Cât de mult scade cererea în zilele cu vreme nefavorabilă (3) față de cele cu vreme bună (1)?

- **Răspuns:** Cererea scade cu **63.02%** în zilele cu ploaie sau zăpadă față de cele cu cer senin.
- **Justificare:** Această scădere masivă arată că sistemul de bike-sharing este extrem de dependent de condițiile meteorologice. Din punct de vedere al business-ului, acest lucru sugerează necesitatea unor strategii de fidelizare sau promoții pentru zilele noroase (starea 2) pentru a atenua pierderile.

Întrebarea 3: Cine închiriază mai mult în weekend/zile libere: utilizatorii ocazionali (casual) sau cei înregistrați (registered)?

- **Răspuns:** Chiar și în weekend, utilizatorii **înregistrați** sunt majoritari, cu o medie de **2959**, față de cei **ocazionali**, care au o medie de **1371**.
- **Justificare:** Deși utilizatorii ocazionali își triplează activitatea în weekend față de zilele lucrătoare, baza de abonați fideli (registered) rămâne principalul pilon de venit al companiei, folosind serviciul constant pentru recreere.

Întrebarea 4: Care a fost ziua record (maximă) din întregul set de date?

- **Răspuns:** Recordul absolut de închirieri a fost de **8714 unități**, înregistrat în data de **15 septembrie 2019**.
- **Justificare:** Această zi record a avut loc în al doilea an de funcționare, în luna septembrie (care este în topul preferințelor), confirmând trendul de creștere al afacerii și popularitatea serviciului în perioadele de tranzit dintre vară și toamnă.

Întrebarea 5: Cum a evoluat numărul de utilizatori (ocazionali vs. înregistrați) între cei doi ani?

- **Răspuns:** Ambele segmente au crescut semnificativ în 2019. Utilizatorii **ocazionali (casual)** au crescut de la o medie de **677 la 1021** (~51%), în timp ce utilizatorii **înregistrați (registered)** au crescut de la **2728 la 4589** (~68%).
- **Justificare:** Creșterea mai accelerată a bazei de utilizatori înregistrați arată că serviciul a reușit să fidelizeze clienții. Aceasta este o veste excelentă pentru business, deoarece utilizatorii înregistrați tind să fie o sursă de venit mai predictibilă și constantă față de cei ocazionali.

Întrebarea 6: Care este impactul vântului puternic asupra numărului de închirieri?

- **Răspuns:** Media închirierilor scade de la **4917** (în zilele cu vânt slab, sub 10 mph) la **3781** (în zilele cu vânt puternic, peste 18 mph).
- **Justificare:** Vântul puternic reduce utilizarea bicicletelor cu aproximativ **23%**. Deși impactul vântului este vizibil și negativ, acesta este mult mai blând decât impactul ploii (care genera o scădere de 63%). Așadar, vântul este un factor de disconfort, dar nu un impediment total pentru utilizatorii experimentați sau pentru navetiști.

```
✓ # Intrebari si raspunsuri specifice setului nostru de date ···

1. Luna cu cele mai multe închirieri medii: Luna 6 (Media: 5772)
2. Scăderea cererii în zilele cu vreme rea: 63.02%
3. În weekend, media utilizatorilor: Casual (1371) vs Registered (2959)
4. Recordul absolut de închirieri: 8714 unități în data 15-09-2019
5. Media utilizatorilor pe ani (2018 vs 2019):
        casual   registered
yr
0    677.40274  2728.358904
1   1021.09589  4589.156164
6. Media închirierilor: Vânt puternic (>18): 3781 vs Vânt slab (<10): 4917
```

Contributia membrilor echipei

1.Secăl Mihnea-Elian

-realizarea codului in VSC Python pana la cerinta 7 inclusiv

-realizarea word-ului pana la cerinta 7 inclusiv

-realizarea primelor 3 intrebari si raspunsuri specifice setului de date

2. Pedestru Adrian-George

-realizarea codului in VSC Python pana la cerinta 14 inclusiv

-realizarea word-ului pana la cerinta 14 inclusiv

-realizarea urmatoarelor 3 intrebari si raspunsuri specifice setului de date

COD SURSA:

```
import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns


# Incarcam setul de date

df=pd.read_csv("D:\\day.csv")


# Incarcam setul de date

df=pd.read_csv("C:\\Users\\elian\\Desktop\\teme\\day.csv")


# Afisam primele 5 randuri din setul de date ca sa intelegem cu ce fel de date lucram

print("Primele 5 randuri din setul de date sunt:")

print(df.head())


# Afisam numarul de inregistrari si de coloane

print("Numarul de inregistrari si de coloane este:",df.shape)

#%%

# Verificam daca exista valori null

print("Valorile lipsa de pe fiecare coloana sunt:")

print(df.isnull().sum())
```

```
# A doua varianta pentru valori null ca sa fim 100% siguri

print("Exista valori lipsa in setul de date?:")

print(df.isnull().values.any())

#%%

# Selectam doar coloanele cu valori numerice relevante pentru a calcula media,mediana,deviatia
standard si cvartiile acestora

cols_numerice = ['temp', 'atemp', 'hum', 'windspeed', 'casual', 'registered', 'cnt']


# Calculam media pentru valorile numerice

print("Media pentru valorile numerice este:")

print(df[cols_numerice].mean())


# Calculam mediana pentru valorile numerice

print("Mediana pentru valorile numerice este:")

print(df[cols_numerice].median())


# Calculam deviata standard pentru valorile numerice

print("Deviatia standard pentru valorile numerice este:")

print(df[cols_numerice].std())


# Calculam cvartiile pentru valorile numerice

print("Cvartiile pentru valorile numerice sunt:")

print(df[cols_numerice].quantile([0.25,0.5,0.75]))
```

```
# Adaugam media,mediana,deviatia standard si cvartiile intr-un singur tabel pentru o vizualizare mai buna

from IPython import display

print("Tabel cu media, mediana, deviata standard si cvartiile pentru valorile numerice:")

display.display(df[cols_numerice].describe().loc[['mean', '50%', 'std', '25%', '75%']])

#%%

# Identificam variabilele categoriale

# Pasul 1: Vedem câte valori unice are fiecare coloană

print("Număr de valori unice per coloană:")

print(df.nunique())


# Pasul 2: Filtrăm coloanele care au mai puțin de 15 valori (acestea sunt categoriile)

categorii = [col for col in df.columns if df[col].nunique() < 15]


print("Variabilele categoriale identificate sunt:")

print(categorii)

#%%

# Calculăm media închirierilor (cnt) pentru diferite grupuri

medie_sezon = df.groupby('season')['cnt'].mean()

medie_vreme = df.groupby('weathersit')['cnt'].mean()

medie_lucru = df.groupby('workingday')['cnt'].mean()


print("Media pe Sezoane (1:Iarna, 2:Primavara, 3:Vara, 4:Toamna):")
```

```
print(medie_sezon)

print("Media pe Vreme (1:Limpede, 2:Nori/Ceață, 3:Ploaie/Zăpadă):")
print(medie_vreme)

print("Weekend/Sărbătoare (0) vs Media Zi Lucrătoare (1):")
print(medie_lucru)

# Realizam un boxplot cu 3 grafice pentru a intelege mai bine diferentele intre medii
plt.figure(figsize=(15, 5))

# Boxplot pentru Sezon
plt.subplot(1, 3, 1)
sns.boxplot(x='season', y='cnt', data=df, color='#79F8F8')
plt.title('Boxplot pentru Sezon')
plt.xlabel('Sezon (1:Iarna, 2:Primavara, 3:Vara, 4:Toamna)')
plt.ylabel('Număr Închirieri (cnt)')

# Boxplot pentru Vreme
plt.subplot(1, 3, 2)
sns.boxplot(x='weathersit', y='cnt', data=df, color='#7FDD4C')
plt.title('Boxplot pentru Vreme')
plt.xlabel('Vreme (1:Limpede, 2:Nori/Ceață, 3:Ploaie/Zăpadă)')
```

```
plt.ylabel('Număr Închirieri (cnt)')


# Boxplot pentru Zi Lucrătoare

plt.subplot(1, 3, 3)

sns.boxplot(x='workingday', y='cnt', data=df, color='#88421D')

plt.title('Boxplot pentru Zi Lucrătoare')

plt.xlabel('Weekend/Sărbătoare (0) vs Media Zi Lucrătoare (1)')

plt.ylabel('Număr Închirieri (cnt)')


# Afisare boxplot-urilor

plt.tight_layout()

plt.show()

#%%

#Excludem coloanele care nu sunt variabile independente (instant, dteday, casual, registered)

# și calculăm corelația cu 'cnt'

corelatii_importante = df.drop(columns=['instant', 'dteday', 'casual',
'registered']).corr()['cnt'].sort_values(ascending=False)


print("Corelația variabilelor independente cu numărul de închirieri (cnt):")

print(corelatii_importante)


# Calculăm și diferența de medie pe ani pentru a susține importanța variabilei 'yr'

print("\nMedia închirierilor pe ani (0=2018, 1=2019):")

print(df.groupby('yr')['cnt'].mean())
```

```
#%%

# Selectăm doar coloanele numerice pentru corelație

df_numerice = df.select_dtypes(include=['int64', 'float64'])


# Calculam matricea de corelatie

corelatie = df_numerice.corr()


# Afișăm harta de corelații

plt.figure(figsize=(12,6))

sns.heatmap(corelatie, annot=True, cmap="coolwarm")

plt.title("Matricea de corelații între variabile")

plt.show()

# %%


from statsmodels.stats.outliers_influence import variance_inflation_factor


# Selectăm variabile pentru exemplu (cele mai importante)

X = df[['temp', 'atemp', 'hum', 'windspeed']]


# Calculăm VIF pentru fiecare variabilă

# Dacă VIF > 10 → coliniaritate puternică

vif = pd.DataFrame()
```

```
vif["Variabila"] = X.columns
vif["VIF"] = [variance_inflation_factor(X.values, i) for i in range(len(X.columns))]

print("VIF înainte de eliminare:")
print(vif)

# Temp si atemp au VIF mare, deci atemp poate fi eliminata din model.
# Eliminăm variabila atemp (are VIF foarte mare)
X = df[['temp', 'hum', 'windspeed']]

# Recalculăm VIF după eliminare
vif2 = pd.DataFrame()
vif2["Variabila"] = X.columns
vif2["VIF"] = [variance_inflation_factor(X.values, i) for i in range(len(X.columns))]

print("\nVIF după eliminarea variabilei 'atemp':")
print(vif2)
# %%
# Creăm o copie a dataframe-ului original
df_dummies = df.copy()

# Eliminăm coloanele care nu sunt necesare pentru model
df_dummies = df_dummies.drop(columns=['instant', 'dteday', 'casual', 'registered', 'atemp'])
```

```
df_dummies = pd.get_dummies(df_dummies, columns=['season', 'weathersit', 'mnth'],
drop_first=True)


# Convertim tot tabelul la tip numeric

df_dummies = df_dummies.astype(float)


# Verificam noul set de date

print("Verificare tipuri de date (trebuie să fie toate float):")

print(df_dummies.dtypes.head())

# %%


# Efectuam Regresia Liniară

import statsmodels.api as sm


df_model = df_dummies # Acum df_model este definit corect


X_clean = df_model.drop(columns=['cnt'])

y_clean = df_model['cnt']


# Adăugăm constanta

X_clean = sm.add_constant(X_clean)

model = sm.OLS(y_clean, X_clean).fit()

print(model.summary())

# %%
```

```
# %%
# Verifica distribuția variabilei dependente 'cnt'
plt.figure(figsize=(7,5))
sns.histplot(df['cnt'], bins=30, kde=True)
plt.title("Distribuția variabilei dependente (cnt)")
plt.xlabel("Număr închirieri")
plt.ylabel("Frecvență")
plt.show()

# %%
# Scatterplot pentru variabilele importante din regresie
plt.figure(figsize=(15,4))

plt.subplot(1,3,1)
sns.scatterplot(x='temp', y='cnt', data=df)
plt.title("Temp vs cnt")

plt.subplot(1,3,2)
sns.scatterplot(x='hum', y='cnt', data=df)
plt.title("Hum vs cnt")

plt.subplot(1,3,3)
sns.scatterplot(x='windspeed', y='cnt', data=df)
```

```
plt.title("Windspeed vs cnt")


plt.tight_layout()

plt.show()

# %%

# Verificăm reziduurile modelului

residuurile = model.resid

plt.figure(figsize=(7,5))

sns.histplot(residuurile, bins=30, kde=True)

plt.title("Distribuția reziduurilor")

plt.xlabel("Reziduuri")

plt.ylabel("Frecvență")

plt.show()

# %%

# Intrebari si raspunsuri specifice setului nostru de date

# Întrebarea 1: Care este luna cu cel mai mare număr mediu de închirieri?

top_luna = df.groupby('mnth')['cnt'].mean().idxmax()

valoare_luna = df.groupby('mnth')['cnt'].mean().max()

print(f"1. Luna cu cele mai multe închirieri medii: Luna {top_luna} (Media:
{valoare_luna:.0f})")


# Întrebarea 2: Cât de mult scade cererea în zilele cu vreme nefavorabilă (3) față de cele cu
vreme bună (1)?

vreme_buna = df[df['weathersit'] == 1]['cnt'].mean()
```

```
vreme_rea = df[df['weathersit'] == 3]['cnt'].mean()

scadere_procent = ((vreme_buna - vreme_rea) / vreme_buna) * 100

print(f"2. Scăderea cererii în zilele cu vreme rea: {scadere_procent:.2f}%")


# Întrebarea 3: Cine închiriază mai mult în weekend: utilizatorii ocazionali (casual) sau cei
înregistrați (registered)?

weekend_data = df[df['workingday'] == 0]

media_casual = weekend_data['casual'].mean()

media_registered = weekend_data['registered'].mean()

print(f"3. În weekend, media utilizatorilor: Casual ({media_casual:.0f}) vs Registered
({media_registered:.0f})")


# Întrebarea 4: Care a fost ziua record (maximă) din întregul set de date?

zi_record = df.loc[df['cnt'].idxmax()]

print(f"4. Recordul absolut de închirieri: {zi_record['cnt']} unități în data {zi_record['dteday']}")


# Întrebarea 5: Cum a crescut segmentul de utilizatori 'Casual' față de 'Registered' între cei doi
ani?

crestere_utilizatori = df.groupby('yr')[['casual', 'registered']].mean()

print("5. Media utilizatorilor pe ani (2018 vs 2019):")

print(crestere_utilizatori)


# Întrebarea 6: Care este impactul vântului puternic asupra numărului de închirieri?

# Considerăm vânt puternic peste 18 mph și vânt slab sub 10 mph

vant_puternic = df[df['windspeed'] > 18]['cnt'].mean()
```

```
vant_slab = df[df['windspeed'] < 10]['cnt'].mean()

print(f"6. Media închirierilor: Vânt puternic (>18): {vant_puternic:.0f} vs Vânt slab (<10): {vant_slab:.0f}")
```